BÁO CÁO KỸ THUẬT RẮN CHẮC • SPIDER-200 BENCHMARK

Kiến Trúc, Protocol và Kết Quả Đánh Giá Spider-200: Paper II / R2 so với Baseline P6

Phân tích thực nghiệm toàn diện trên 200 câu hỏi Cross-Domain, đánh giá hiệu năng Schema Context Coverage-v2, thời gian đáp ứng và các giới hạn suy luận.

NGÀY CẬP NHẬT
2026-09-29 (Asia/Bangkok)

TRẠNG THÁI GATE R2
IN_PROGRESS (P6 vẫn giữ Default)

MÔ HÌNH HẠ TẦNG
Qwen3-14B Q4 • SQLite Local

0.1 TỔNG QUAN HỆ THỐNG

Phạm Vi Hệ Thống & Vị Trí Của Nhánh Nghiên Cứu R2

Runtime Text-to-SQL

Chạy local hoàn toàn trên SQLite/Ollama. Nhận đầu vào là câu hỏi tự nhiên, CatalogSnapshot và index tương ứng; trả ra SQL candidate kèm provenance.

Mốc Incumbent P6

Cấu hình đã qua kiểm định Gate chính thức. Sử dụng 6 GPU layers, planner_v2, generator_v4 và budget context 1.200 token.

Nhánh Thách Thức R2

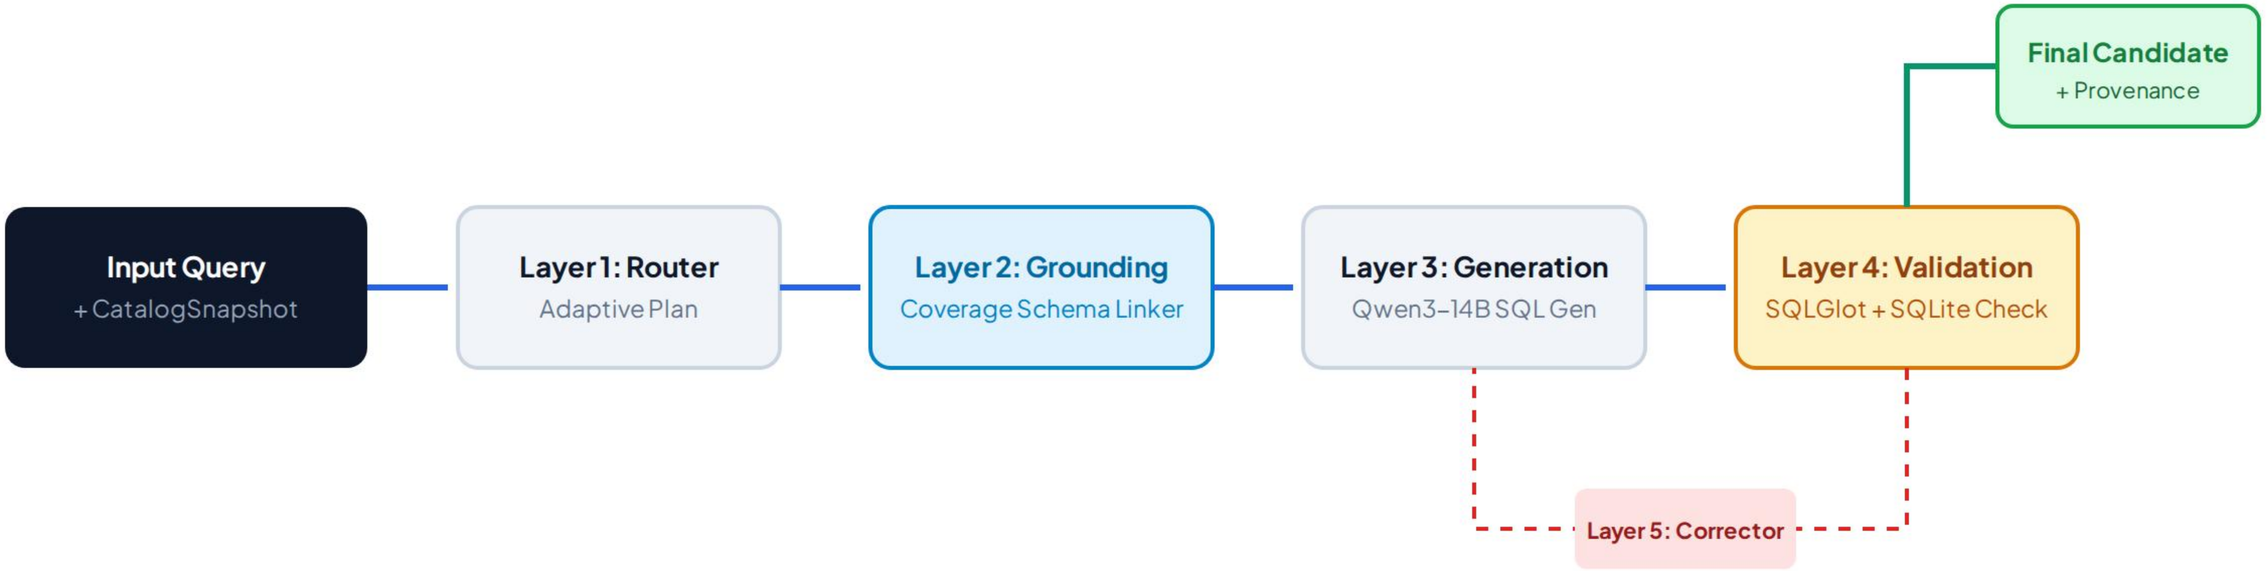
Thử nghiệm cải tiến ở 3 lớp: Adaptive Planning, Schema Linker Coverage và Bounded Corrector với tối đa 2 lần sửa lỗi LLM.

Phạm Vi Đánh Giá Spider-200 Cross-Domain

Đánh giá này chạy ở chế độ `candidate_mode=legacy` và không sử dụng Typed Semantic Proof. Kết quả phản ánh hiệu năng của cấu hình tích hợp R2 trên tập dữ liệu Spider-200.

0.1 KIẾN TRÚC RUNTIME

Luồng Xử Lý Câu Hỏi Qua Các Lớp Module Trong Runtime



0.2 CẤU HÌNH THỬ NGHIỆM

Ma Trận Cấu Hình Giữa Các Chế Độ Chạy Spider-200

Cấu Hình	Schema Context	Correction Budget	Thiết Lập Phần Cứng & Guard	Vai Trò Bằng Chứng
P6 Lịch Sử	Trung bình 3.45 bảng; budget 1.200 token	Tối đa 1 repair / 1 LLM call	6 GPU layers; Guard P6 lịch sử	**Incumbent Benchmark (130/200)**
R2 Legacy Mới	`schema_context_mode=legacy`; trung bình 1.35 bảng	Tối đa 2 repairs / 2 LLM calls	1 GPU layer; Cooldown & Unload active	Control nội bộ thử nghiệm (120/200)
R2 Coverage-v2	`schema_context_mode=coverage`; trung bình 3.48 bảng	Tối đa 2 repairs / 2 LLM calls	1 GPU layer; Clock cap 700 MHz cứng	**Ứng viên tích hợp mới (128/200)**

0.3 KẾT QUẢ CHÍNH

So Sánh Kết Quả Chính Tựu Trung Trên 200 Câu Hỏi

130 / 200

P6 LỊCH SỬ (65.00%)

P50: 58.51s • P95: 85.29s

120 / 200

R2 LEGACY MỚI (60.00%)

P50: 67.37s • P95: 163.51s

128 / 200

R2 COVERAGE-V2 (64.00%)

P50: 69.89s • P95: 156.86s

R2 Coverage so với R2 Legacy

+8 Net Gain (18 Gain / 10 Loss)

Coverage sửa lỗi thiếu Schema của nhánh Legacy hiệu quả.

R2 Coverage so với P6 Lịch Sử

-2 Net Loss (4 Gain / 6 Loss)

Chưa đủ điều kiện để thay thế P6 trên sản phẩm chính.

TOÁN HỌC THỐNG KÊ

Công Thức Kiểm Định McNemar Cho Mẫu Phụ Thuộc Cặp

Đánh giá ý nghĩa thống kê giữa hai mô hình dựa trên các trường hợp bất đồng ý kiến (Discordant Pairs):

$$\chi^2 = \frac{(\,|b - c|\, - 1)^2}{b + c}$$

Trong đó b là số câu mô hình mới đúng/cũ sai (Gain), và c là số câu mới sai/cũ đúng (Loss).

R2 Coverage vs P6 Lịch Sử

Gain (b): 4 | **Loss (c):** 6

p-value ≈ 0.754 (Exact Two-sided)

Chưa có bằng chứng thống kê cho thấy R2 vượt trội hơn P6.

R2 Coverage vs R2 Legacy

Gain (b): 18 | **Loss (c):** 10

p-value ≈ 0.185 (Exact Two-sided)

Cải thiện nội bộ rõ rệt nhưng cần đánh giá thêm mẫu.

1.0 EXECUTIVE SUMMARY

Kết Luận Điều Hành & Quyết Định Quản Trị Gate

- **Chưa Đạt Mục Tiêu Vượt Baseline P6:** R2 Coverage-v2 đạt 128/200 so với P6 130/200 (-2 câu). Giữ P6 làm Default/Champion trong hệ thống.
- **Xác Nhận Giá Trị Module Schema Coverage:** Sửa triệt để lỗi thiếu context của R2 Legacy, tăng 120 → 128/200 (+8 Net Gain nội bộ).
- **Vấn Đề Đánh Đổi Latency:** P50 tăng +19.46% (69.89s vs 58.51s) và P95 tăng +83.92% (156.86s vs 85.29s). Bị ảnh hưởng bởi Guard Unload và 1 GPU Layer.
- **Trọng Tâm Nghiên Cứu Tiếp Theo:** Chuyển hướng từ Schema Linking sang Semantic Plan, Grain, Projection và Anti-join để giải quyết 66 case lỗi chung.

2.0 ĐỐI CHIẾU SỐ LIỆU

Phân Tích Số Liệu Chi Tiết Theo Phân Loại Độ Khó

Phân Loại Độ Khó / Tập	Mẫu Số	P6 Lịch Sử	R2 Legacy Mới	R2 Coverage-v2	Chênh Lệch R2–P6
Easy	107	**83 (77.5%)**	83 (77.5%)	80 (74.7%)	**-3**
Medium	53	**27 (50.9%)**	21 (39.6%)	26 (49.0%)	-1
Hard	29	16 (55.2%)	12 (41.4%)	**17 (58.6%)**	**+1**
Extra Hard	11	4 (36.4%)	4 (36.4%)	**5 (45.5%)**	**+1**
Holdout / Regression	**100 / 100**	**67 / 63**	**61 / 59**	**65 / 63**	**-2 / 0**

2.0 HIỆU NĂNG VẬN HÀNH

Phân Tích Latency P50/P95 & Telemetry Phần Cứng

P50 Predict Latency

69.89s

+11.38s (+19.46%) so với P6 (58.51s)

P95 Predict Latency

156.86s

+71.57s (+83.92%) so với P6 (85.29s)

Thời Gian Model Load

21.69s

Do chính sách Unload Model giữa các câu

Nguyên Nhân Kỹ Thuật Gây Chênh Lệch Thời Gian Đáp Ứng

1. **Cấu hình GPU:** R2 chỉ dùng 1 GPU Layer kèm Hard Clock Cap 700MHz, trong khi P6 sử dụng 6 GPU Layers.
2. **Chi phí Unload/Reload:** Guard wrapper mới giải phóng VRAM sau mỗi case khiến thời gian load trung vị tăng từ 0.30s lên 21.69s.
3. **Token Prompt Tăng:** Prompt dài hơn từ 1.178,5 lên 1.263,5 tokens do Schema Context mở rộng.

2.0 PAIRED ANALYSIS

Ma Trận Tương Quan Paired Gain / Loss Chi Tiết

Coverage-v2 so với Legacy Mới

Cả hai cùng ĐÚNG: 110 câu

Cả hai cùng SAI: 62 câu

Gain (Coverage sửa Legacy): 18 câu

Loss (Legacy đúng, Coverage sai): 10 câu

Thế thuần: **+8 câu** (Chứng minh Schema Context khắc phục được lỗi)

Coverage-v2 so với P6 Lịch Sử

Cả hai cùng ĐÚNG: 124 câu

Cả hai cùng SAI: 66 câu

Gain (R2 sửa P6): 4 câu

Loss (P6 đúng, R2 làm sai): 6 câu

Thế thuần: **-2 câu** (Không bù đắp được các câu Easy bị mất)

3.0 CHI TIẾT KIẾN TRÚC

So Sánh Kiến Trúc Chi Tiết Giữa P6 Mốc và R2 Coverage

Lớp Kiến Trúc	P6 Baseline (Incumbent)	R2 Coverage-v2 (Challenger)
Planner / Generator	`planner_v2` + `generator_v4` cố định	Adaptive Router (195 Baseline Preserve, 4 DIN-SQL Enhance)
Grounding / Linker	Hybrid top-20, context 3.45 bảng	Hybrid top-20 + Mode `Coverage` (3.48 bảng, full schema)
Correction Policy	Tối đa 1 repair / 1 LLM call	Tối đa 2 repairs / 2 LLM calls
Typed Challenger	Không kích hoạt	Chưa kích hoạt Proof trên Spider (chạy `candidate_mode=legacy`)

4.1 CẢI TIẾN GROUNDING

Cơ Chế Schema Linker Opt-in: Bounded FK Closure

Thuật Toán Coverage Linker:

- ✓ **Full Catalog:** Đưa toàn bộ Bảng/Cột nếu vừa Budget (≤ 6 bảng & ≤ 1.200 token).
- ✓ **FK Closure Boundary:** Với DB lớn, tự động mở rộng theo liên kết Khóa Ngoại từ các bảng chính.
- ✓ **Bảo Tồn Evidence:** Giữ nguyên các cột/bảng bắt buộc do BM25/BGE-M3 truy hồi.

```
// Triển khai tại coverage_linker.py if len(catalog.tables) ⩽ 6 and token_count ⩽ 1200: return render_full_schema(catalog) else: owners = retrieve_owner_tables(query) closure = expand_fk_closure(owners, depth=2) return render_bounded_schema(closure)
```

TOÁN HỌC ĐÁNH GIÁ

Công Thức Đo Lường Độ Phủ Schema Context (Recall)

Độ phủ Schema được tính bằng tỉ lệ giữa các thành phần Bảng/Cột xuất hiện trong Context và Gold SQL:

$$\text{Recall}_{\text{Table}} = \frac{|\ T_{\text{Context}} \cap T_{\text{Gold}}\ |}{|\ T_{\text{Gold}}\ |}$$

$$\text{Recall}_{\text{Column}} = \frac{|\ C_{\text{Context}} \cap C_{\text{Gold}}\ |}{|\ C_{\text{Gold}}\ |}$$

Kết Quả Thực Nghiệm R2 Coverage

Table Recall: 1.00 (179/199 case chứa full DB)
Column Recall: 1.00 trên mọi context tạo ra
FK Closure Recall: 0.985 (chỉ thiếu 3 cạnh join)

4.0 CẢI TIẾN MỚI

Tóm Tắt Các Cải Tiến Trọng Điểm Từ Báo Cáo Trước

1. Schema Linker Opt-in

Tạo module coverage ưu tiên giữ nguyên chủ thể bảng, cột bắt buộc và bao đóng FK. Tăng trung bình 1.35 → 3.48 bảng/context.

2. Tách Biệt Model-free Evaluation

Đo độ phủ Schema độc lập với độ chính xác thực thi. Chứng minh Schema Recall = 1.0 chưa đủ để đảm bảo Execution Accuracy = 1.0.

3. Fail-closed Failover Protocol

Khóa biến môi trường trong TMUX, kiểm tra Provenance trước khi Resume để tránh việc chạy nhầm Chế độ Schema cũ.

4.3 QUẢN TRỊ CHẠY

Khóa Provenance & Sửa Lỗi Fail-Closed TMUX Failover

Sự Cố Run v1 (Invalid)

Do TMUX không nhận biến môi trường `SCHEMA_CONTEXT_MODE`, 141/200 predictions bị rơi về chế độ `legacy`.

→ Đã đánh dấu *.invalid-run.json và loại khỏi báo cáo chính.

Cải Tiến Protocol Run v2

Launcher chủ động Pin mode trực tiếp vào môi trường TMUX, thực hiện kiểm tra SHA-256 Provenance trước khi cho phép Resume.

→ Bảo đảm 200/200 predictions hoàn tất chính xác chế độ Coverage.

6.1 PHÂN TÍCH LỖI SÂU

Chẩn Đoán Offline: Mức Độ Thiếu Schema Trong Bảng Context

Tập Predictions Đánh Giá	Đủ Gold Table & Column	Thiếu ≥ 1 Gold Table	Thiếu ≥ 1 Gold Column
P6 Đúng (130)	**130 / 130 (100%)**	0	0
P6 Sai Có Context (69)	**67 / 69 (97.1%)**	0	2
R2 Legacy Sai Có Context (79)	**45 / 79 (57.0%)**	33	34
R2 Coverage Sai Có Context (71)	**71 / 71 (100%)**	**0**	**0**

*Kết luận chẩn đoán: 71/71 câu sai của R2 Coverage **đều chứa đầy đủ Bảng và Cột mà Gold SQL yêu cầu**. Do đó, nguyên nhân thất bại không còn là do thiếu Schema Context.

6.2 PHÂN TÍCH AST SQL

Tín Hiệu Sai Lệch Cấu Trúc AST SQL Trên 71 Case Thất Bại

- Sai Lệch Hàm Aggregate (COUNT/SUM/AVG) 18 cases
- Thiếu / Dư Từ Khóa DISTINCT 11 cases
- Sai Lệch Bảng Sử Dụng (Population/Owner) 15 cases
- Sai Lệch Subquery & Set Operations 9 cases
- Sai Lệch Số Lượng Phép JOIN 15 cases
- Sai Lệch Mệnh Đề GROUP BY / WHERE 8 cases

6.3 BÀI HỌC VỀ REGRESSION

Phân Tích Nguyên Nhân 6 Câu P6 Đúng Nhưng R2 Làm Sai

1. Trả Dư Thuộc Tính Đầu Ra

SQL tạo ra trả về thêm cột không được hỏi trong câu hỏi nguyên bản (2 cases).

2. Sai Thứ Tự & Cực Trị

Nhầm lẫn giữa ORDER BY ASC/DESC hoặc chọn sai giá trị LIMIT khi có trùng lặp (2 cases).

3. Chọn Sai Bảng Population

Thay đổi bảng chứa Metric dù cả 2 bảng đều đáp ứng từ khóa lexical (1 case).

4. Mismatch Hình Dạng Kết Quả

Bị lỗi Result Shape Mismatch dù cú pháp biểu kiến gần giống với P6 (1 case).

6.4 RỦI RO KHI MỞ RỘNG CONTEXT

Vì Sao Schema Context Rộng Hơn Lại Gây Ra Lỗi Lặp?

Hiện Tượng Trôi Ngữ Nghĩa Khi Có Quá Nhiều Cột

Khi đưa Full Schema vào Prompt, mô hình ngôn ngữ có xu hướng **chọn nhầm các cột mô tả** thay vì cột mã định danh, hoặc nhầm lẫn giữa tên thuộc tính tương tự ở các bảng khác nhau.

- → **Chuyển đổi Mã -> Mô tả:** Mô hình dùng `type_description` thay vì `type_code` làm hỏng phép Group.
- → **Thay thế Anti-Join:** Thay thế phép phủ định tập hợp bằng điều kiện so sánh trực tiếp `<>` trên hàng con.
- → **Gom nhóm theo Tên:** GROUP BY theo Name thay vì Primary Key ID làm mất các bản ghi trùng tên.

6.5 PHÂN TÍCH ROUTING

Đánh Giá Hiệu Quả Route BASELINE_PRESERVE & DIN-SQL

Phân Bố Nhãn Route Trong R2 Coverage

- **BASELINE_PRESERVE:** 195 cases (125 đúng / 70 sai)
- **DIN_SQL_ENHANCE:** 4 cases (3 đúng / 1 sai)
- **UNKNOWN / NO_ROUTE:** 1 case (0 đúng / 1 sai)

Lưu ý quan trọng: Nhãn `BASELINE_PRESERVE` không đồng nghĩa với việc tái sử dụng nguyên văn SQL của P6. Runtime R2 vẫn thực hiện lập kế hoạch và sinh SQL mới hoàn toàn.

Mẫu Thử DIN-SQL

Số lượng 4 case là quá nhỏ để đưa ra kết luận tổng quát về module DIN-SQL. Cần thử nghiệm riêng trên tập câu hỏi phức tạp ghép nối.

6.6 GIỚI HẠN CHẨN ĐOÁN

Khoảng Cách Giữa Spider Benchmark & Thực Tế Doanh Nghiệp

Đặc Điểm Spider-1.0 Benchmark

- Database kích thước nhỏ, schema đơn giản.
- Không có phân quyền tenant isolation.
- Không xử lý câu hỏi mơ hồ hoặc chứa từ lóng.

Yêu Cầu Enterprise SQL (Spider 2.0)

- Workflow dài, đa dialect và biến đổi schema liên tục.
- Kiểm soát truy cập Read-only & Audit Log nghiêm ngặt.
- Cam kết SLA về Latency và Quota tài nguyên.

9.1 KHUYẾN NGHỊ P0

Ưu Tiên P0: Khóa P6 Control & Môi Trường Guard Đồng Nhất

1. Tạo P6 Control Mới

Khóa cố định Source, Config, Prompt và Index của P6. Đo đạc lại P6 dưới đúng môi trường Guarded Profile hiện tại để loại bỏ nhiễu Latency.

2. Cơ Chế Fallback An Toàn

Nếu Challenger bị Timeout hoặc Validation thất bại, tự động trả về kết quả Incumbent P6 nhằm bảo vệ các câu Easy đang có.

9.2 KHUYẾN NGHỊ P0

Thắt Chặt Semantic Contract Thay Vì Chỉ Thêm Schema

Tập trung giải quyết **66 câu lỗi chung** bằng cách ràng buộc các điều khoản ngữ nghĩa trước khi sinh SQL:

Population Owner
Xác định chính xác bảng chủ thể chứa dữ liệu.

Entity Identity
Bắt buộc GROUP BY theo Primary Key ID.

Join Path Validation
Kiểm tra đường nối FK hợp lệ trong Schema.

9.3–9.5 KHUYẾN NGHỊ P1

Điều Kiện Chuyển Giao Module & Protocol Chống Leakage

Tiêu Chí Gate	Điều Kiện Bắt Buộc Để Promote Module Mới
Accuracy Gate	Phải vượt P6 Control khớp Profile trên tập Database/Schema chưa từng dùng để thiết kế.
Non-regression Gate	Challenger không được làm thay đổi kết quả đúng của Incumbent nếu không có Proof rõ ràng.
Latency SLA Gate	P95 Predict Latency phải nằm trong ngân sách cho phép (không chấp nhận P95 > 150s).
Anti-leakage Protocol	Tuyệt đối không viết Rule theo ID, tên DB hoặc Gold SQL của 72 case lỗi đã mở.

KẾT THÚC BÁO CÁO

Cảm Ơn Qúy Reviewer Đã Theo Dõi!

Trạng thái Ledger: P6 tiếp tục giữ vị trí Default Champion. Mọi đóng góp cải tiến sẽ tiếp tục được thử nghiệm dưới quy trình Kiểm Định Nghiêm Ngặt.

Master Plan & Ledger: `realistic_project_creation_codex.md`