

Revision: 55f8da1e • Trạng thái: PROPOSED

Kế Hoạch Chuyển Giao Paper Thành Implementation

Hệ thống Agentic Text-to-SQL Local cho Model 14B • Báo cáo Review Mentor & Kế hoạch Thực thi sau Gate P6

MỤC ĐÍCH

Review Mentor & Gate Planning

NGÀY CHỐT HIỆN TRẠNG

2026-08-28


NGUỒN DỰ ÁN

realistic_project_creation_codex.md

1. Kết Luận Điều Hành (Executive Summary)

Tổng Quan Dự Án

Đã hoàn thành Gate P6 với hạ tầng Text-to-SQL local đầy đủ (Schema retrieval, SQL read-only, CLI/API/UI). Tuy nhiên, **chất lượng semantic chưa đủ tin cậy** cho câu hỏi ngoài demo.



📖 Đề xuất 5 cơ chế nghiên cứu có vai trò tách biệt:

- PRACTIQ

Phân loại Answer / Clarify / Cannot trước khi sinh SQL.
- DIN-SQL

Phân rã intent, độ khó & lập kế hoạch chi tiết theo Clause.
- CHESS

Đưa Metric contract, DB values & Provenance vào context.
- CHASE-SQL

Sinh max 3 candidate khác logic & chọn bằng evidence.
- APEL

Thu feedback từ Output/Assumption người dùng đánh giá được.

Quyết định: Không làm đồng thời 5 paper. Gate kế tiếp duy nhất là R0 (Khóa baseline & Failure intelligence).

2. Quy Định Đo Lường & Phạm Vi Claim

Methodology

3 Loại con số trong Báo cáo

ĐÃ ĐO Kết quả có report: Revision & manifest tái lập. Trình bày như kết quả chính thức.

MỤC TIÊU Ngưỡng quyết định: Tiêu chuẩn Promote/Reject trước khi chạy experiment.

ƯỚC LƯỢNG Effort & Gain prior: Ước tính thời gian máy/effort để lập kế hoạch.

Nguyên tắc Ngưỡng Mục Tiêu

65.00% là baseline lịch sử **ĐÃ ĐO**.
≥70.00% là **MỤC TIÊU** gần (cần tăng ròng ít nhất +10 case đúng = 140/200).
Tuyệt đối không viết "dự kiến đạt 70%" nếu chưa chạy thực tế!

Trạng Thái Phạm Vi Claim Hiện Tại

Hạng Mục	Trạng Thái Chính Xác	Ghi Chú Kỹ Thuật
Core engineering P0–P6	VERIFIED	Đã xác nhận hoàn thành theo completion ledger tại Gate P6.
Spider-200 (65%) & Olist-60 (95%)	HISTORICAL BASELINE	Baseline lịch sử của revision 1509faa (gen v4 / corr v3).
Post-P6 (Gen v6 / Corr v5)	HARDENED	Đã xử lý một số incident, chưa có benchmark accuracy mới .
R0 Failure-analysis tooling	AVAILABLE	Đã có ở revision 55f8da1 ; chưa run full / reviewer agreement.
Full Spider dev (1,034 case)	NOT STARTED	Evaluator self-test 1034/1034 không phải model accuracy.
Research upgrades R1–R5	PROPOSED	Chưa được promote, không gọi là implemented.

3. Baseline Lịch Sử & Bức Tranh Phân Tích Lỗi

Baseline Metrics

Kết Quả Độ Khó & Precision

Chỉ Số / Độ Khó	ĐÃ ĐO	Mẫu Số	Diễn Giải
Spider Execution Acc	65.00%	130/200	Semantic accuracy còn thấp
Spider Valid Candidate	99.50%	199/200	Parser/Runtime không là bottleneck
Spider Easy	77.57%	83/107	Fast path tương đối ổn
Spider Medium	50.94%	27/53	Cần reasoning có cấu trúc
Spider Hard	55.17%	16/29	Sample nhỏ, chưa suy diễn quá mức
Spider Extra-Hard	36.36%	4/11	Cần candidate diversity
Olist Result Accuracy	95.00%	57/60	Domain contracts hiệu quả

Retrieval Recall & Failure Breakdown

Phân loại lỗi chính: **EXECUTION_MISMATCH**
97.14% số lỗi (68/70 case). SQL chạy thành công nhưng trả về kết quả sai nghĩa! **97.1%**



4. Kiến Trúc Hiện Tại & Khoảng Trống Boundary

Question → Router/Decomposer/Planner → Hybrid Retrieval → Candidate Generator → SQLGlot/Executor → Bounded Correction → Result Presenter

Boundary	Hiện Có (Baseline)	Thiếu Sót (Gap)	Hậu Quả Hiện Tại
Question	Router query / clarify / write	Multi-interpretation, answerability, ambiguity classification	Ép câu mơ hồ thành một SQL duy nhất
Planning	LogicalPlan one-shot	Complexity route, clause dependency, output grain contract	Độ chính xác Medium / Extra-hard giảm mạnh
Grounding	Table / column / FK retrieval	Metric semantics, safe values, entity provenance	Đúng cột nhưng sai owner / value / grain
Generation	1 Candidate duy nhất	Logic-diverse pool & oracle metric	SQL chạy sai kết quả không thể kích hoạt corrector
Validation	Syntax / safety / shape check	Calibrated semantic evidence & disagreement handling	Self-confidence dễ bị hiểu nhầm là xác suất đúng
Feedback	Rating / category theo run	Output comparison, review queue, verified label	Thumbs-down không đủ chi tiết để học

5. Câu Hỏi Nghiên Cứu & Giả Thuyết Có Thể Bác Bỏ

Research Hypotheses

Câu hỏi trung tâm:
Làm thế nào một hệ Agentic Text-to-SQL dùng model local 14B giảm câu trả lời “SQL chạy được nhưng sai nghĩa”, đồng thời hỏi lại hoặc từ chối đúng khi câu hỏi không đủ điều kiện, mà vẫn nằm trong resource envelope của laptop ($P95 \leq 60s$)?

ID	Giả Thuyết Nghiên Cứu	Điều Kiện Bác Bỏ (Falsification Criteria)
H0	Failure taxonomy sẽ cho thấy top-3 cause bao phủ $\geq 60\%$ số lỗi	Cause phân tán ngẫu nhiên, hoặc reviewer agreement $< 90\%$.
H1	Answerability gate giảm confident-wrong $\geq 30\%$ trên challenge set	False-refusal $> 3\%$ hoặc clarification không giúp giải quyết case.
H2	Clause plan giúp medium + hard tăng ≥ 5 điểm phần trăm	Overall/easy regress hoặc plan không làm tăng oracle recoverability.
H3	Semantic/value evidence giúp filter/join slice tăng ≥ 3 điểm	Context size tăng nhưng accuracy không tăng, hoặc có privacy leakage.
H4	Best-of-3 tạo oracle headroom ≥ 8 điểm trên routed-hard slice	Candidate trùng lặp logic hoặc oracle gap thực tế quá nhỏ.
H5	Output-based feedback cho non-coder đạt agreement $\geq 80\%$	User chọn theo format / row count thay vì đúng nghĩa semantics.

6. Paper I — PRACTIQ: Phân Loại Answerability Trực Tiếp

NAACL 2025


Nguồn: Dong et al. (NAACL 2025). Đưa vào khái niệm câu hỏi mơ hồ (ambiguous) và không thể trả lời (unanswerable).

Quy trình xử lý quyết định (Decision Boundary):

RawQuestion $\rightarrow$ InterpretationSet[1..3] $\rightarrow$ AnswerabilityDecision
(ANSWER | CLARIFY | CANNOT_ANSWER | SAFE_REJECT)

Mục Tiêu Promote & Chỉ Số Đo Lường:

- ✓ **Routing Macro-F1:** Đạt ≥ 0.80 trên 3 class answer/clarify/cannot.
- ✓ **Ambiguity Recall:** $\geq 85\%$ (Phát hiện ít nhất 26/30 câu mơ hồ).
- ✓ **Answerable False-Refusal:** $\leq 3\%$ (Tối đa 1/40 câu hỏi đúng bị từ chối nhầm).
- ✓ **Confident-Wrong Drop:** Giảm $\geq 30\%$ số câu sai tự tin so với pipeline không gate.



⚠ Kill Rule cho PRACTIQ:

Reject hoặc đơn giản hóa ngay nếu hệ thống hỏi lại $> 15\%$ câu answerable, yêu cầu user phải biết schema, hoặc tăng "safe-resolution" bằng cách abstain hàng loạt.

7. Paper II — DIN-SQL: Clause Planning

NeurIPS 2023

Nguồn: Pourreza & Rafiei. Phân rã prompt thành Schema Linking, Phân loại độ khó, Decomposition & Self-Correction.


AcceptedInterpretation → SemanticLinkPlan → ComplexityDecision → ClausePlan (Select, Source/Join, Filter, Group, Order, Limit) → Generator

Work Breakdown (P1-P8) & Experiment:

- ✓ **P1-P3:** Mở rộng LogicalPlan, Complexity Classifier rule-first, LLM decompose khi case khó.
- ✓ **P4-P8:** Plan Validator kiểm tra FK/Owner/Grain trước khi đẩy sang Generator.

Mục Tiêu Promote:

Medium+Hard accuracy tăng $\geq +5\%$. Overall Spider tăng $\geq +4$ case (+2%). Easy regression ≤ 1 case .



8. Paper III — CHESS: Context Tối Thiểu & Semantic Evidence

Context & Evidence

Nguồn: Talaei et al. Đưa Database Values, Descriptions & Metric Contracts vào context để sửa lỗi sai Owner, Grain & Business Meaning.



Value Indexing

Profile bounded với distinct cap, length cap, exact lookup trước embedding. Ngăn chặn leaky raw dumps.



Metric Catalog

Khai báo Alias, Unit, Grain, Population & Owner rõ ràng. Ví dụ: định nghĩa chuẩn cho Olist gross revenue.



FK Component

Khôi phục Join-Edge Recall từ 86.36% lên cao hơn mà không làm giảm Connected Precision.

Mục Tiêu & Ràng Buộc An Toàn (G1 - G9):

Filter/Join/Grain EX: Tăng +3 điểm trên root-cause slice. **Warm Grounding P95:** Giữ mức $\leq 1.0s$. **Data Privacy / Leakage:** 100% Audit Pass (Deny PII/free text).

9. Paper IV — CHASE-SQL: Candidate Khác Nhau Về Logic

ICLR 2025

🔗 Nguyên Lý Multi-Path Selection

Chỉ áp dụng với **case Hard + Answerable**. Sinh tối đa 3 candidate khác nhau về logic cấu trúc (Divide-and-conquer, Exec-plan, Evidence-constrained). Simple case giữ nguyên 1 candidate để bảo vệ latency P95.

🔽 Deduplication & Selection

Lọc trùng lặp bằng AST normalization trước khi chạy. Selector dựa trên deterministic evidence, result-shape invariants và consensus. Nếu bất đồng không rõ ràng: chuyển thành **CLARIFY**.

Các Chỉ Số Đo Lường & Mục Tiêu Promote (C1 – C8)

ORACLE HEADROOM

≥ +8%

Trên routed-hard slice

SELECTOR ACCURACY

≥ 80%

Chọn đúng best candidate

NET EX GAIN

≥ +3%

Tăng ròng trên hard cases

LATENCY BOUND

≤ 1.8x

So với single candidate


10. Paper V — APEL: Thu Feedback Không Cần Biết SQL

EMNLP 2024

Nguồn: Gu et al. Cho phép người dùng không biết kỹ thuật SQL vẫn đánh giá và phản hồi chính xác thông qua Output Tables & Key Assumptions.

Quy Trình Thu Feedback (F1 – F8):

- ✓ **Presenter Layer:** Hiển thị kết quả kèm giả định nghiệp vụ dạng plain language.
- ✓ **User Feedback:** Thumbs down kích hoạt hỏi về Output/Assumption thay vì bắt sửa SQL.
- ✓ **Audit Queue:** Chuyển feedback vào hàng đợi Active Learning để gán nhãn verify.
- ✓ **Target Agreement:** Đạt $\geq 80\%$ đồng thuận giữa non-coder feedback và expert verification.



Giá trị cốt lõi:

Tạo vòng lặp cải tiến liên tục cho dữ liệu local mà không đòi hỏi Domain Expert phải giỏi viết câu lệnh SQL phức tạp.

11. Lớp Đánh Giá Toàn Diện & Paired Transitions

📋 Các Tầng Metric Đánh Giá

- ✓ **Execution Accuracy (EX):** Đo kết quả thực thi chính xác trên db benchmark.
- ✓ **Test-Suite Accuracy (TSA):** Đánh giá bằng database mutation/distillation để chống false positive.
- ✓ **Paired Transition Analysis:** Đo trực tiếp chuyển biến Win / Loss / Tie giữa B0 và R_x trên cùng manifest.

🛡️ Nguyên Tắc Gold Firewall

- ✓ Gold benchmark **chỉ tồn tại trong module eval**, tuyệt đối không đi vào runtime.
- ✓ Không dùng glossary suy từ Gold SQL vào prompt.
- ✓ Raw dataset, database index, predictions & gold reports nằm ngoài kho Git.

Bảng Báo Cáo Mẫu Chuyển Biến (Paired Report Table Structure):

Baseline EX	Candidate EX	Wins (+ Case)	Losses (- Case)	Net Delta
-------------	--------------	---------------	-----------------	-----------

12. Kiến Trúc Đích Hợp Nhất & Module Boundaries

Target Architecture



Ràng Buộc Kỹ Thuật Bắt Buộc (Guardrails)

- ✓ Runtime hoàn toàn local, không dùng paid API.
- ✓ Typed contracts bằng Pydantic, bounded token budgets.
- ✓ Read-only executor và SQLGlue safety policy khắt khe.

Tiêu Chí Kiểm Thử

- ✓ Deterministic integration tests cho mọi early exit route.
- ✓ Resource Governor đảm bảo RAM và CPU nằm trong hạn mức laptop.
- ✓ Mọi nâng cấp R1-R5 phải qua Gate R0 trước khi promote.

13. Lộ Trình Thực Thi & Các Gate Quyết Định

Roadmap

Thực hiện tuần tự theo các Gate kiểm soát chất lượng nghiêm ngặt. Phân tích Pareto lỗi tại R0 sẽ quyết định thứ tự thực hiện DIN-SQL hay CHESS.



🚩 **Cam Kết Đầu Ra Gate R0:** Tạo dataset nhãn lỗi có inter-reviewer agreement $\geq 90\%$, xác định chính xác ưu tiên cho R2.

Image Sources



https://opensource.posit.co/blog/2026-08-17_pyorbital-0-6-0/featured_hu_e07a72863c5da888.png

Source: opensource.posit.co



<https://montecarlo.ai/wp-content/uploads/2023/01/Freshly-data-platform-architecture-jpg.webp>

Source: montecarlo.ai



https://www.slideteam.net/media/catalog/product/cache/1280x720/a/g/agile_software_development_flow_chart_slide01.jpg

Source: www.slideteam.net