

Từ Paper tới Kiến trúc Triển khai: Luận đề Nghiên cứu cho Agentic Text-to-SQL Local

Giải quyết triệt để lỗi "SQL chạy được nhưng sai nghĩa" (Execution Mismatch) bằng model local 14B dưới giới hạn phần cứng laptop thương mại.

PHẠM VI
Local Laptop / 14B LLM

MỤC TIÊU CHÍNH
Semantic Accuracy & Interactivity

ĐÁNH GIÁ
Distilled Test Suites

Tóm tắt Luận đề Nghiên cứu

Bottleneck đã dịch chuyển từ "hệ thống chạy được không" sang "hệ thống hiểu đúng ý nghĩa không". 68/70 thất bại trên Spider-200 là lỗi EXECUTION_MISMATCH.

🎯 Câu hỏi Nghiên cứu Trọng tâm

"Làm thế nào một hệ Agentic Text-to-SQL dùng model local 14B có thể giảm câu trả lời 'SQL chạy được nhưng sai nghĩa', đồng thời biết hỏi lại/từ chối đúng khi mơ hồ, mà không vượt ngưỡng latency/tài nguyên laptop?"

- **Engineering nền tảng:** Workflow có trạng thái, SQL read-only, schema retrieval, bounded correction, gold firewall đã hoàn tất.
- **Thực tế bottleneck:** Parser hay syntax rules không còn tạo bước nhảy accuracy. Cần giải quyết bản chất semantic reasoning.

🔧 Model: Qwen3-14B Q4_K_M (6 GPU layers, Seed 42)

🧩 5 Cơ chế Paper Hỗ trợ Hợp nhất

1. **PRACTIQ:** Quyết định Direct/Clarify/Reject trước khi sinh SQL.
2. **DIN-SQL:** Phân rã bài toán thành schema linking, complexity & clause plan.
3. **CHESS:** Grounding giá trị DB/metadata với context tối thiểu đủ nghĩa.
4. **CHASE-SQL:** Đa dạng logic candidate & chọn lựa dựa trên evidence.
5. **APEL:** Cho non-coder sửa hệ thống qua so sánh output/assumption.

Bảng chứng Thực nghiệm Baseline (Khóa 2026-08-27)

Tên chỉ số / Benchmark	Kết quả Baseline	Ý nghĩa chẩn đoán kỹ thuật & định hướng
Spider-200 Execution Accuracy	130 / 200 (65.00%)	Cross-domain generalization còn khoảng trống lớn cần lấp đầy.
Spider Valid Candidate Rate	199 / 200 (99.50%)	Syntax & workflow đã vững, không phải bottleneck chính hiện tại.
Spider Holdout / Regression	67% / 63%	Chưa thấy hiện tượng holdout collapse ở mức aggregate.
Spider Easy / Medium / Hard / Extra-Hard	77.57% / 50.94% / 55.17% / 36.36%	Reasoning giảm sâu khi cấu trúc phức tạp (cần Clause Decomposition).
Spider Failure Analysis	68 / 70 MISMATCH	SQL chạy được nhưng kết quả sai nghĩa hoàn toàn. Lỗi cú pháp chỉ chiếm 2 case.
Schema Table / Column Recall@20	100.00% / 99.65%	Schema Retrieval gần bão hòa; không nên tiếp tục tăng Top-K retrieval.
Join-Edge Recall	86.36%	Xác định Join path/evidence vẫn là điểm yếu cụ thể cần gia cố.
Olist-60 Result Acc / First-Pass / Holdout	95.00% / 85.00% / 100.00%	Semantic contract theo domain đạt hiệu quả rất cao. Correction đóng góp 6 case.
Olist VI / EN Performance	29/30 (VI) vs 28/30 (EN)	Xử lý song ngữ không phải bottleneck aggregate hiện tại.
Latency P50 / P95 (Spider & Olist)	58.51s-61.92s / 85.29s-91.62s	Đuôi latency P95 dài; chưa thể áp dụng multi-agent vô điều kiện.

Phân tích Incident Free-Form & Suy luận

🚨 Tình huống Thực tế (Case e4e905f4...)

Câu hỏi: Đếm số khách hàng quay lại theo customer_unique_id .

Diễn biến thất bại ban đầu:

- Candidate 1 dùng cột ở sai owner → Lỗi UNKNOWN_COLUMN sau 71.92s.
- Correction sửa lại vẫn sai scalar shape. Validator tạo false positive.

Kết quả sau khi Hardening (Run 170c567e...):

```
SELECT COUNT(*) FROM customer_order_facts WHERE order_count > 1;
```

→ Trả về: 2,997 khách hàng | Latency: 71.08 giây.

🧠 Những Suy luận Rút ra



- ✓ **Đã suy ra:** Pipeline hiện tại đủ ổn định để tập trung nghiên cứu chất lượng Semantic Quality.
- ✓ **Đã suy ra:** Semantic Mismatch và Query Complexity nguy hiểm hơn nhiều so với lỗi Syntax tổng quát.
- ⚠ **Không suy ra:** Self-confidence (VD: Model báo 95%) *không phải xác suất đúng*. Bắt buộc dùng observable evidence.

Ma trận Chẩn đoán Ưu tiên Nghiên cứu

Ưu tiên	Chẩn đoán từ Project hiện tại	Cơ chế Paper giải quyết	Quyết định Nghiên cứu Triển khai
P0	68 execution mismatches chưa có nhãn nguyên nhân gốc (root-cause) chi tiết.	Test-Suite + Failure Analysis	Freeze baseline và gán nhãn failure chi tiết theo AST/Result trước khi đổi kiến trúc.
P1	User hỏi mở hồ, typo, out-of-data; router hiện tại chưa biểu diễn nhiều cách hiểu.	PRACTIQ (NAACL '25)	Xây dựng Question Reliability Contract bắt buộc trước khi cho phép sinh SQL.
P1	Medium Acc chỉ 50.94%, Extra-hard 36.36%; Planner hiện tại là one-shot.	DIN-SQL (NeurIPS '23)	Lập Clause Plan và Complexity Router; loại bỏ Chain-of-Thought dài vô điều kiện.
P1	Schema recall cao nhưng Join-edge recall chỉ 86.36%; hay sai owner/grain/value.	CHESS (2024/2025)	Xây Semantic Catalog kết hợp Bounded Value & Entity Retrieval có nguồn gốc (provenance).
P2	Một candidate duy nhất tạo variance lớn; correction chỉ phản ứng thụ động.	CHASE-SQL (ICLR '25)	Áp dụng Logic-diverse Best-of-3 chọn lọc bằng Selector (chỉ dành riêng cho case khó).
P2	Feedback của non-coder chưa tạo được dữ liệu huấn luyện semantic chất lượng.	APEL (EMNLP '23)	So sánh Output/Assumption cho non-coder + Tạo Flywheel dữ liệu đã qua kiểm duyệt.
GUARD	Latency P95 tới 85-92s; nguy cơ vượt giới hạn nhiệt/điện laptop local.	Adaptive Architecture	Mọi module mới bắt buộc phải tuân thủ Budget, Cache, Checkpoint và Kill Rules.

Paper I – PRACTIQ (NAACL 2025)

P1 IMPLEMENTATION Question Reliability Contract

Bản chất Paper: Đặt ranh giới quyết định (Decision Boundary) trước khi sinh SQL để phân loại 3 trạng thái: ANSWER, CLARIFY, hoặc CANNOT_ANSWER.

Luồng Chuyển giao Kiến trúc:

RawQuestion → NormalizedQuestion (typo, alias, VI/EN)
→ InterpretationSet[1..3] (metrics, filters, assumptions)
→ AnswerabilityDecision (ANSWER | CLARIFY | CANNOT_ANSWER)
→ Chuyển sang SQL Pipeline chỉ khi đủ evidence.

Tiêu chí Chấp nhận (Acceptance Criteria):

- Ambiguity Recall ≥ 85% | Answerable False-Refusal ≤ 3%
- Clarification Success ≥ 80% | Confident-Wrong giảm ≥ 30%



Paper II — DIN-SQL (NeurIPS 2023)

Phân rã bài toán Semantic phức tạp thành các giao diện nhỏ chuyên biệt (Decomposition Interfaces) thay vì dùng một prompt tổng hợp.



1. Semantic Link Plan

Nhận diện Entity, Metric, Dimension, Value và Evidence Owner trong câu hỏi mà không phụ thuộc vào cú pháp SQL cụ thể.



2. Complexity Decision

Phân loại mức độ: **Simple**, **Aggregate**, **Multi-join**, hoặc **Nested/Set/Window** để định tuyến luồng xử lý phù hợp.



3. Clause Plan & Validator

Lập kế hoạch từng mệnh đề: Output grain, Join path, WHERE, GROUP/HAVING, Subqueries; kiểm tra tính nhất quán (Consistency) trước khi sinh code.

Quy tắc Chấp nhận (Promote Rule): Medium + Hard Acc tăng $\geq 5\%$, Overall tăng $\geq 2\%$, Easy không giảm quá 1 case.

KILL RULE: PLAN DÀI GÂY LAN TRUYỀN LỖI SANG EASY

Paper III – CHESS (2024/2025)

P1 GROUNDING Context Tối thiểu nhưng Đủ nghĩa

Cung cấp chính xác thông tin grounding (Metadata + Giá trị thực trong DB) nhằm giải quyết điểm yếu Join-edge recall (86.36%) và lỗi Grain/Ownership.



Các Thành phần Kiến trúc Trích xuất:

✓

Safe Value Lookup: Tra cứu giá trị thực trên các cột allowlist.


✓

Metric Catalog: Lưu trữ Alias, Đơn vị (Unit), và Khung thời gian (Time grain).

✓

FK-Connected Component: Đảm bảo retrieval có đúng connected graph.

Value index bắt buộc được hash, đánh version và tuân thủ tuyệt đối quy định không chứa PII.



Mục tiêu kiểm chứng: Filter/Join slice tăng ≥ 3 điểm hoặc Overall tăng ≥ 2 điểm. Latency grounding p95 < 1 giây.

Paper IV — CHASE-SQL (ICLR 2025)

3

Adaptive Candidates Max

Chỉ áp dụng cho case khó, không chạy phung phí

🔗 Đa dạng Logic (Logic-Diverse Multi-Path)

Sinh các candidate có hướng suy luận khác nhau thay vì đổi seed ngẫu nhiên:

Path 1: Clause-plan decomposition

Path 2: Divide-and-conquer theo sub-query

Path 3: Evidence-constrained alternative

Selector Engine: Chuẩn hóa AST để deduplicate. Sử dụng deterministic validation, result-shape invariants và evidence coverage để chọn candidate tối ưu.

📌 Nếu bất đồng lớn giữa các candidate mà thiếu evidence → Chuyển về trạng thái **CLARIFY** chứ tuyệt đối không ép chọn ngẫu nhiên.

Paper V — APEL (EMNLP 2023)

Cho phép Non-Coder đóng góp supervision chất lượng cao thông qua việc so sánh Output và Assumption trực quan thay vì đọc code SQL.

Cơ chế So sánh Output (Output Cards)

Khi các candidate tạo ra kết quả bất đồng, UI hiển thị 2 Output Cards đã được ẩn thông tin nhạy cảm (sanitize).

- ▶ Giải thích sự khác biệt bằng ngôn ngữ nghiệp vụ (Metric, Filter, Time grain).
- ▶ Giấu truy vấn SQL vào phần Advanced.
- ▶ User chọn "đúng ý" hoặc nhập reason code đơn giản.

Flywheel Dữ liệu An toàn

Quy trình biến tương tác người dùng thành dữ liệu cải tiến hệ thống bền vững:


User Action → Record Queue (với Catalog version & Provenance)
→ PII & Leakage Audit → Verified Example Store
→ Huấn luyện LoRA (Chỉ thực hiện sau khi dedup & DB-disjoint).

⚠️ Nghiêm cấm tự động dùng Raw Thumbs-down làm data huấn luyện.

Kiến trúc Triển khai Hợp nhất

Workflow 3 Đường Thoát Sớm (Early-Exit)

```
Raw User Question
|
▼ [Layer 1: PRACTIQ] Question Reliability
|— Ambiguous → [EXIT 1: Ask Clarification]
|— Unanswerable → [EXIT 2: Explain Missing Evidence]
▼ (Answerable)
[Layer 2: CHES + DIN-SQL] Grounding & Clause Plan
▼ [Layer 3: CHASE-SQL] Multi-Path Candidate Generation
▼ [Layer 4: Deterministic Guard] Validation & Test Suite
|— Failed → Bounded Correction (1 pass)
▼ [Layer 5: Selection] Best Candidate / Consensus
|— High Uncertainty → [EXIT 3: Propose Options]
▼
[Layer 6: APEL] User Result & Feedback Flywheel
```



Đặc điểm Thiết kế Core:

Kiến trúc dạng Pipeline có trạng thái (Stateful), quản lý tài nguyên nghiêm ngặt, ưu tiên phản hồi an toàn chính xác hơn là đoán mò.

Giới hạn Tài nguyên Laptop Local & Guardrails

Đảm bảo hệ thống hoạt động bền vững trên laptop commercial mà không gặp sự cố quá nhiệt, cạn RAM hoặc Power-stop.

Bounded Latency Budget

Tổng thời gian phản hồi cho luồng interactive phải đạt **P50 < 45s** và **P95 < 60s**.
Luồng 3 candidates chỉ chạy khi đã được router xác nhận thuộc hard-slice.

Peak Memory & VRAM Cap

Giới hạn tối đa RAM cho phép $\leq$ **24 GB**, VRAM $\leq$ **12 GB**. Không giữ đồng thời nhiều instance model nặng trong bộ nhớ.

Context Token Window

Giới hạn Prompt Context $\leq$ **4,096 tokens**. Tránh nhồi nhét toàn bộ database schema vào prompt nhờ có CHESS Selector.

Automatic Kill Switch

Tự động dừng (Abort) nếu phát hiện vòng lặp correction > 2 lần hoặc thời gian xử lý đơn vụ vượt quá 90 giây để bảo vệ pin và nhiệt độ.

Lộ trình Thực nghiệm (Research Gates R0 – R5)

Gate R0: Baseline Freeze & Failure Taxonomy

Gán nhãn chi tiết 70 lỗi Spider & 3 lỗi Olist. Khóa nguyên bản Test Suite.

Gate R1: Question Reliability (PRACTIQ)

Đo Ambiguity macro-F1, False refusal < 3%. Tích hợp Clarification contract.

Gate R2: Structured Reasoning (DIN-SQL)


Đo Clause F1, kiểm tra mức tăng accuracy trên nhóm Medium & Hard.

Gate R3: Grounding & Provenance (CHESS)

Đo Value recall, Join-edge recall. Kiểm tra không rò rỉ dữ liệu.

Gate R4 & R5: Multi-Path Diversity & User Flywheel

Đo Pass@3, Selector recovery rate, Non-coder agreement & Flywheel audit.



Công thức Đo lường & Promotion Scorecard

📊 Công thức Toán học Đo lường

1. Test-Suite Execution Accuracy (EX_ts):

$$EX_{ts} = \frac{\sum_{i=1}^N \zeta \quad \forall t \in T_i : Exec(\hat{y}_i, t) = Exec(y_i^*, t)}{N}$$

2. Candidate Selection Recovery (Rec_sel):

$$Rec_{sel} = \frac{Acc_{selected} - Pass@1}{OraclePass@k - Pass@1}$$

📋 Promotion Scorecard

Spider-200 Target:	≥ 72.00% (+7.0%)
Spider Hard/Extra-Hard:	≥ 60.00% / ≥ 45.00%
Olist-60 Guardrail:	≥ 95.00% (No regression)
Ambiguity Recall / Precision:	≥ 85.00% / ≥ 80.00%
Latency P95 Budget:	≤ 60.0s (Interactive)

Định hướng Chủ ý Chưa làm & Bước tiếp theo

⊘ Phạm vi Chủ ý KHÔNG Làm (Out of Scope)

- ✗ Không fine-tune model 14B toàn phần khi chưa đóng gói xong R0-R3.
- ✗ Không tự xây dựng multi-agent framework phức tạp bên ngoài LangGraph local core.
- ✗ Không thêm dữ liệu ngoài không thể tái lập hoặc các bộ prompt tùy biến bí mật.

▶ Bước đi Duy nhất Tiếp theo (Gate R0)

Thực hiện **Gate R0**: Chạy công cụ AST & Result Diff tự động để gắn nhãn phân loại nguyên nhân gốc cho 70 case Spider failures và 3 case Olist failures.

```
</> Script: python -m scripts.annotate_failures --manifest benchmark_full.json
```


Image Sources




<https://static.vecteezy.com/system/resources/thumbnails/070/595/295/small/futuristic-digital-circuit-blueprint-abstract-technology-grid-with-glowing-blue-lines-on-dark-background-perfect-for-ai-systems-high-tech-interfaces-and-cyber-data-design-illustration-vector.jpg>

Source: www.vecteezy.com



<https://omdia.tech.informa.com/-/media/tech/omdia/assetfamily/2025/06/25/market-landscape-conversational-ai-2025--from-assistants-to-agentic/assetfamily005.png?rev=3cf20fcfa5694944a4d40033e76c74cd&hash=84C4383EA65B92580D76CDA67F6FE4D9>

Source: omdia.tech.informa.com



<https://dbschema.com/blog/design/steps-to-design-relational-schema/relational-database-schema-guide.png>

Source: dbschema.com



https://www.mdpi.com/loT/loT-06-00069/article_deploy/html/images/loT-06-00069-g001-550.jpg

Source: www.mdpi.com



<https://images.presentationgo.com/2025/09/timeline-roadmap-light-bg-powerpoint-google-slides.png>

Source: www.presentationgo.com