

BÁO CÁO SỰ CỐ, BUG & BÀI HỌC KIẾN TRÚC DỰ ÁN

Tổng kết 20 chặng kỹ thuật, phân tích nguyên nhân gốc rễ (Root Causes) và bài học tối ưu hóa hệ thống Text-to-SQL AI Runner.

Thời gian đánh giá: 2026-08-17 | Mã Commit: c748621 → 68fde00

Tổng quan Bối cảnh Dự án (Project Context)



Mục tiêu Hệ thống

Xây dựng hệ thống **Text-to-SQL Autonomous Engine** chạy hoàn toàn Local (On-premise) có khả năng tự động dịch câu hỏi ngôn ngữ tự nhiên thành SQL chính xác trên CSDL lớn (Olist, Spider-200).



Ràng buộc Hạ tầng


Chạy trực tiếp trên phần cứng giới hạn (Consumer Laptop GPU 8GB-12GB VRAM), không phụ thuộc vào Cloud API ngoại vi, đòi hỏi tối ưu hoá gắt gao về Latency và Memory Leakage.

Phạm vi Kiểm thử (Validation scope)

Hệ thống trải qua 6 cột mốc lớn (P0 → P6.3) từ xử lý schema, Semantic RAG, AST SQL parsing, đến Supervisor Hardware Guardrails.

Kiến trúc Tổng thể Pipeline Text-to-SQL

- ✓ **1. Schema Linking & RAG:** Lọc bảng và cột liên quan qua Hybrid Retrieval (Vector + Keyword BM25).
- ✓ **2. LLM Generator:** Sử dụng Qwen local model sinh câu lệnh SQL có kiểm soát Grammar.
- ✓ **3. AST & Shape Validator:** Kiểm tra cú pháp SQL với SQLGlot và kiểm tra kiểu dữ liệu đầu ra (Scalar/Table).
- ✓ **4. Self-Correction Loop:** Tự động sửa lỗi runtime SQL tối đa 1 lần thử lại (1-shot repair).
- ✓ **5. Hardware Supervisor:** Giám sát nhiệt độ/điện năng GPU để ngăn sập nguồn.



Phân loại & Quy chuẩn Phân tích Sự cố

FIXED (ĐÃ SỬA)

Lỗi Đã Khắc Phục

Đã xác định nguyên nhân gốc rễ (Root cause), sửa code và passing toàn bộ các bài Test tái lập (Regression Tests).

MITIGATED (GIẢM THIỂU)

Lỗi Giảm Thiểu

Đã kiểm soát được rủi ro vỡ trận hệ thống nhưng giới hạn phần cứng/nền tảng cốt lõi vẫn chưa thể loại bỏ hoàn toàn.

OPEN (CHƯA GIẢI QUYẾT)

Lỗi Mở / Tồn Động

Các vấn đề mang tính bản chất nghiên cứu AI/NLU hoặc đòi hỏi hạ tầng cao hơn chưa đạt ngưỡng target.

Cột mốc P0: Xử lý Grammar & Định dạng LLM

Sự cố F-P0-01: Grammar Compiler Crash

Mô tả: Khi truyền Pydantic Schema có chứa Regex nâng cao vào Ollama Grammar Compiler làm ứng dụng treo hoặc crash ngay lập tức.

Impact: Tỷ lệ gọi API sinh JSON thành công là 0%.

Giải pháp Khắc phục (Resolution)

Adapter Layer: Viết middleware làm sạch bớt các biểu thức Regex phức tạp khỏi JSON Schema trước khi đưa vào LLM engine.

Post-validation: Thực hiện Pydantic validation ở tầng application sau khi LLM phản hồi.

FIXED

Cột mốc P1: Nghẽn I/O Ổ đĩa & Tối ưu WSL2


Sự cố F-P1-02: Extreme I/O Latency trên WSL2

SQLite database đặt tại mount ổ Windows (/mnt/d/) bị chậm tới 45x lần do giao thức RPC cross-OS overhead.

Kiến trúc Build Mới (Atomic Rename)

Khởi tạo và ghi toàn bộ SQLite DB tạm trên định dạng file native Linux (ext4 /tmp), sau khi hoàn tất mới di chuyển Atomic Rename sang ổ cứng lưu trữ.

FIXED - SPEEDUP 45X



Cột mốc P2: Bẫy "Cú pháp đúng - Logic sai"

Vấn đề F-P2-01: AST Parser lọt lưới

Các đoạn text nhiễu hoặc SQL không trọn vẹn vẫn pass qua parser chuẩn. Hệ thống đã bổ sung luật bắt buộc Root AST Node phải là **exp.Query**.

FIXED

Bài học F-P2-05: Semantic Integrity Error

Dù SQL hợp lệ cú pháp 100%, nhưng có **14/18 câu sai lệch kết quả logic**: nhầm lẫn JOIN key, sai hàm gom nhóm (Aggregate) hoặc nhầm Business Domain logic.

MITIGATED

Cột mốc P2.1: Tối ưu Latency Sinh chuỗi Thinking

95.6s

LATENCY BAN ĐẦU (FULL THINKING)

20.2s

LATENCY SAU TỐI ƯU

-78.8%

THỜI GIAN CHỜ GIẢM

Nguyên nhân & Giải pháp Tối ưu

F-P2-04: Mặc định model Qwen suy luận chuỗi Thinking quá dài không cần thiết cho các câu SQL đơn giản. Giải pháp: Ép tham số think=false và giới hạn Context Window ở mức 4096 tokens.

Cột mốc P3: Định tuyến Context & Schema RAG

Thất bại F-P3-06: RRF Weight Lỗi

Thuật toán Reciprocal Rank Fusion (RRF) thiết lập trọng số $k=0.01$ gây mất các cột thông tin hiếm (Low-frequency Columns). Đã chuyển sang bằng trọng số Vector + BM25.

FIXED

Thất bại F-P3-04: Bỏ quên Warm-up Latency

Quá trình tính toán Vector Embedding cho Query mất thêm 3-5 giây nhưng ban đầu bị bỏ qua trong báo cáo benchmark. Đã cập nhật tính đúng latency E2E.

FIXED


Cột mốc P4: Vòng lặp Sửa lỗi Tự động (Self-Correction)

Sự cố F-P4-02: Repair Infinite Loop

Model Corrector liên tục lặp lại đúng câu lệnh SQL lỗi cũ khi cố gắng sửa lỗi Runtime, gây tốn tài nguyên và treo vĩnh viễn.

Cơ chế Guardrail Sửa lỗi

- ✓ **Fingerprint Stop:** Băm (Hash) câu SQL cũ; nếu lặp lại câu đã thử thì ngừng ngay.
- ✓ **Hard Cap 1-shot:** Chỉ cho phép tối đa 1 lần thử sửa tự động để bảo đảm Latency.



Cột mốc P5: Đánh giá Thực tế trên Olist Dataset

78.33%

CHỈ SỐ ĐỘ CHÍNH XÁC (ACCURACY) OLIST-60

Chưa đạt target ban đầu (90.0%)

Phân tích Top 3 Nhóm Lỗi Còn Tồn Động

1. **Aggregate Grain (40% lỗi):** Nhầm lẫn giữa tính tổng theo từng Order hay theo từng Customer.

2. **Population Filter (35% lỗi):** Bỏ sót điều kiện trạng thái đơn hàng (WHERE status = 'delivered').

3. **Order/Limit (25% lỗi):** Nhầm lẫn giữa TOP N cao nhất và thấp nhất do ambiguity câu hỏi.

Cột mốc P5.1: Sự cố Thermal Throttling Laptop

Sự cố F-P5-03: Sập nguồn do Quá nhiệt


Chạy 60 câu hỏi liên tục ép GPU hoạt động 100% công suất làm công suất đỉnh lên 139W, vượt ngưỡng nhiệt độ an toàn gây sập nguồn phần cứng (Thermal Shutdown).

Hệ thống Giám sát Supervisor v2

- ✓ **Giới hạn GPU Layer:** Hạ số layer offload xuống 6 layers để chừa khoảng trống cho GPU thở.
- ✓ **Thermal Supervisor:** Poll nhiệt độ mỗi 0.5s; tự động Pause hoặc Kill process nếu GPU > 85°C.

FIXED

Cột mốc P6: Benchmark Spider-200 Stratified



Kết quả Phân tầng theo Độ khó

Phân tầng (Difficulty)	Số lượng	Accuracy %
Easy & Medium	120	82.50%
Hard	50	58.00%
Extra-Hard	30	36.36%

Kết luận: Các câu SQL phức tạp nhiều JOIN và Subquery là rào cản chính của LLM kích thước nhỏ (7B/14B parameters).

Cột mốc P6.2: Bẫy Mất liên kết Schema (Coherence)

Sự cố F-P6-02: Bịa cột trên View Aggregate

Hiện tượng: LLM tự động bịa ra tên cột không tồn tại khi truy vấn trên các View ảo hoặc bảng gom nhóm phức tạp.

Root cause: RAG trả về danh sách cột rời rạc mà không cung cấp ngữ cảnh quan hệ khóa ngoại (Foreign Key).

Khắc phục qua Graph Linker

Bắt buộc thuật toán Schema Linking phải chọn các thành phần liên thông (Connected Components) trên đồ thị CSDL thay vì chọn ngẫu nhiên các cột có Score cao nhất.

FIXED

Cột mốc P6.3: Khôi phục Hợp đồng Dữ liệu Scalar

Sự cố: Scalar Mismatch

Câu hỏi yêu cầu trả về 1 con số đơn lẻ (ví dụ: "Có bao nhiêu khách hàng?"), nhưng SQL trả về danh sách hàng ngàn dòng chứa toàn bộ ID khách hàng.

Cơ chế Signal Signal Repair

Bổ sung tầng Shape Guard: Nếu prompt chứa từ khóa đếm/đơn lẻ, Validator kiểm tra AST phải có hàm COUNT() hoặc SUM(). Nếu thiếu, gắn tín hiệu **SCALAR_AGGREGATE** ép Corrector sửa lại.

FIXED

Dòng thời gian Tiến hóa & Xử lý Bug Dự án



Bảng Tổng hợp 8 Sự cố Trọng yếu

Mã Lỗi	Chặng	Mô tả Ngắn Sự cố	Giải pháp Cốt lõi	Trạng thái
F-P0-01	P0	Pydantic Regex làm crash Ollama Grammar	Adapter sanitize schema trước khi gửi	FIXED
F-P1-02	P1	Chậm I/O do đặt SQLite ở Windows Mount	Build temp DB trên ext4 Linux native	FIXED
F-P2-04	P2	Thinking latency quá cao (95.6s)	Ép think=false + Limit context 4096	FIXED
F-P4-02	P4	Corrector lặp lại đúng câu SQL lỗi cũ	Dùng Fingerprint Stop + Cap 1-shot	FIXED
F-P5-03	P5	GPU overheat sập nguồn laptop (139W)	Hardware Supervisor & Offload 6 layers	FIXED
F-P6-01	P6	Accuracy Spider Extra-Hard quá thấp	Chưa giải quyết triệt để do model size	OPEN

Bài học Kinh nghiệm Kiến trúc (Best Practices)



1. Never Trust LLM Raw Output

Mọi câu lệnh SQL từ LLM bắt buộc phải đi qua 3 lớp phòng thủ: Grammar Constraint, AST Validation và Shape Contract trước khi cho phép đưng vào DB thật.



2. Hardware-Aware Software

Khi triển khai On-Premise / Edge AI, phần mềm phải chủ động lắng nghe chỉ số phần cứng (Nhiệt độ, VRAM, Power) để điều tiết workload thích ứng.



3. Deterministic Evaluation

Cần tách biệt rõ giữa "SQL chạy được không lỗi" và "SQL trả về đúng dữ liệu kinh doanh" thông qua bộ test suite đa dạng.

Các Tồn tại Chưa thể Tuyên bố Thành công

⚠ Những Giới hạn Cần Thành thực Ghi nhận

- ✓ **Latency vẫn còn cao cho sản phẩm Realtime:** Tốc độ phản hồi trung bình 20s - 70s vẫn chưa đạt chuẩn Chatbot thời gian thực cho người dùng cuối.
- ✓ **Độ chính xác Extra-Hard Query còn yếu:** Chỉ đạt ~36% đối với các truy vấn phức tạp đòi hỏi ghép nối >4 bảng.
- ✓ **Self-Correction mang tính xác suất:** Vòng lặp sửa lỗi tự động chỉ thành công khoảng 45% số trường hợp, không phải là một sự đảm bảo chắc chắn 100%.